



**UNIVERSIDAD
TECNOLÓGICA
METROPOLITANA**
del Estado de Chile

Análisis Estadístico de Datos de Ventas

Inferencia y Modelado para Cruz Morada

Integrantes: Matías Hidalgo

Amaru Aros

Fecha de entrega: 10 de julio de 2026

Asignatura: Computación Paralela y Distribuida

Profesor: Sebastián Salazar Molina

Santiago de Chile

Resumen

El presente informe documenta el diseño y la implementación de una solución computacional destinada a procesar y analizar un archivo consolidado de ventas de la cadena farmacéutica ficticia Cruz Morada. El conjunto original contiene 3.242.878 registros y exige un tratamiento que controle el consumo de memoria, mantenga la reproducibilidad y aproveche el paralelismo disponible. La solución implementada organiza el trabajo en un *pipeline* de validación por fragmentos, preprocesamiento, análisis exploratorio, inferencia estadística, modelado predictivo y visualización mediante un *dashboard* local.

La etapa de validación se ejecutó con cuatro procesos y fragmentos de 100.000 filas. El procedimiento procesó 33 fragmentos, conservó 3.239.993 transacciones válidas y descartó 2.885 registros inconsistentes. El análisis descriptivo reveló una distribución altamente asimétrica del monto pagado, con una mediana de \$7.662 y una media de \$10.180,54. Las pruebas inferenciales mostraron diferencias significativas entre canales y una asociación positiva moderada entre el porcentaje de descuento y el monto aplicado. El modelo principal, basado en *HistGradientBoostingRegressor*, alcanzó un R^2 de 0,9368 en el conjunto de prueba, un error absoluto medio de \$1.683,57 y un error cuadrático medio de \$3.651,64.

El informe también expone limitaciones relevantes: la variable **UNIDADES** es constante, la partición de entrenamiento y prueba es aleatoria, algunos identificadores categóricos se tratan numéricamente y no se registraron las especificaciones completas del procesador y la memoria del equipo de prueba. En consecuencia, los resultados se interpretan como evidencia predictiva y asociativa dentro de los datos observados, no como demostración causal ni como garantía de extrapolación.

Palabras clave: procesamiento paralelo, análisis estadístico, ventas, inferencia, regresión, series temporales, reproducibilidad.

Índice general

Resumen	i
1. Introducción y contexto	1
1.1. Objetivo general	1
1.2. Objetivos específicos	2
2. Datos, entorno y reproducibilidad	3
2.1. Archivo de entrada	3
2.2. Entorno de ejecución documentado	4
2.3. Reproducibilidad	5
3. Arquitectura de la solución y paralelismo	6
3.1. Flujo general	6
3.2. Validación paralela por fragmentos	6
3.3. Control de memoria y condiciones de carrera	7
3.4. Rendimiento observado	8
3.4.1. Comparación de estrategias disponibles	8
4. Datos y preprocesamiento	10
4.1. Validación de calidad	10
4.2. Valores faltantes	11
4.3. Variables derivadas	11
4.4. Valores atípicos	11
4.5. Estandarización	12
5. Análisis exploratorio estadístico	14
5.1. Estadística descriptiva	14
5.2. Distribuciones y normalidad	15
5.3. Correlaciones	19
5.4. Asociaciones y diferencias entre grupos	20

5.5. Patrones temporales	23
6. Inferencia estadística	27
6.1. Criterio de decisión	27
6.2. Hipótesis exigidas por el enunciado	27
6.2.1. Ticket promedio en APP y WEB	27
6.2.2. Descuento y unidades vendidas	28
6.3. Hipótesis propias	28
6.3.1. Diferencias de monto entre canales	28
6.3.2. Asociación entre descuento y monto	28
6.3.3. Asociación entre edad y monto	28
6.3.4. Diferencias de monto según género	28
7. Modelado predictivo y descriptivo	30
7.1. Modelo no lineal principal	30
7.2. Regresión lineal interpretable	31
7.3. Comparación de modelos	32
7.4. Extrapolabilidad y riesgos de validación	34
8. Dashboard y comunicación de resultados	35
9. Dificultades, soluciones y lecciones aprendidas	36
10. Limitaciones metodológicas	38
11. Cumplimiento de la rúbrica	39
12. Conclusiones y recomendaciones	41
A. Comandos de ejecución	42
B. Glosario	43
C. Justificación de bibliotecas	45

Índice de figuras

4.1. Resumen del periodo y resultados de preprocesamiento presentados por el <i>dashboard</i>	13
5.1. Estadística descriptiva mostrada en el <i>dashboard</i>	15
5.2. Resultados de las pruebas de normalidad.	16
5.3. Distribución del monto aplicado. La cola derecha confirma la presencia de compras de alto valor.	17
5.4. Distribución del porcentaje de descuento. Se observan niveles comerciales discretos, especialmente alrededor de 20 %, 35 %, 40 % y 50 %.	18
5.5. Matriz de correlación de Spearman para el periodo completo.	19
5.6. Correlaciones y valores p presentados por el <i>dashboard</i>	20
5.7. Pruebas de asociación y comparación de grupos.	21
5.8. Distribución del monto aplicado según canal. CCT presenta visualmente la mediana más alta; una comparación por pares sería necesaria para identificar qué canales difieren entre sí.	22
5.9. Resumen del análisis temporal generado.	23
5.10. Ventas diarias del periodo.	24
5.11. Descomposición aditiva de la serie temporal en componente observada, tendencia, estacionalidad y residuo.	25
7.1. Resumen de los modelos y métricas presentado por el <i>dashboard</i>	33

Índice de cuadros

2.1. Diccionario resumido de variables de entrada.	3
2.2. Configuración de ejecución registrada.	4
3.1. Métricas registradas de rendimiento y volumen.	8
3.2. Estado de las estrategias de ejecución.	8
4.1. Resultados de validación del archivo original.	10
5.1. Estadísticas descriptivas principales.	14
6.1. Resumen de decisiones inferenciales.	29
7.1. Desempeño del modelo no lineal en el conjunto de prueba.	30
7.2. Desempeño de la regresión lineal.	31
7.3. Diagnósticos principales de la regresión lineal.	31
7.4. Comparación predictiva entre modelos.	32
9.1. Dificultades estructuradas por problema, causa, solución y lección.	36
11.1. Matriz de cumplimiento del enunciado.	39

Índice de algoritmos

1.	Validación paralela y escritura determinista	7
----	--	---

Introducción y contexto

Cruz Morada enfrenta la necesidad de transformar un volumen considerable de transacciones en información útil para la toma de decisiones. Aunque el ejercicio académico proporciona un único archivo consolidado, su tamaño impide adoptar un enfoque ingenuo que cargue y procese la totalidad de los registros durante todas las etapas. La solución debe combinar control de memoria, paralelismo, trazabilidad y rigor estadístico.

El trabajo se desarrolló en el marco de la asignatura Computación Paralela y Distribuida. La propuesta no se limita a producir estadísticas aisladas: organiza un flujo completo que valida registros, genera variables analíticas, detecta valores atípicos, estudia asociaciones, contrasta hipótesis y entrena modelos predictivos. La arquitectura conserva resultados intermedios auditables en formatos *Parquet* y *JSON*, además de gráficos en formato *PNG*.

El análisis escrito adopta una perspectiva formal y distingue entre significancia estadística, relevancia práctica y capacidad predictiva. Esta separación resulta indispensable debido al gran tamaño muestral, ya que valores p extremadamente pequeños pueden acompañar asociaciones de magnitud reducida.

1.1 Objetivo general

Diseñar e implementar una solución computacional eficiente, reproducible y escalable para procesar y analizar los datos de ventas de Cruz Morada, utilizando lectura por fragmentos, paralelismo y técnicas estadísticas apropiadas.

1.2 Objetivos específicos

1. Validar y limpiar las transacciones sin cargar innecesariamente el archivo completo en memoria.
2. Implementar procesamiento paralelo en las etapas que admiten independencia entre tareas.
3. Construir variables derivadas útiles para caracterizar el comportamiento de compra.
4. Describir distribuciones, relaciones, valores atípicos y patrones temporales con rigor estadístico.
5. Contrastar las hipótesis exigidas y formular al menos tres hipótesis adicionales.
6. Desarrollar y evaluar un modelo predictivo mediante una partición de entrenamiento y prueba de 70/30.
7. Presentar los resultados mediante un informe técnico y un *dashboard* local.

Datos, entorno y reproducibilidad

2.1 Archivo de entrada

El archivo principal se carga desde la línea de comandos mediante la ruta `data/ventas_completas.csv`. Aunque el enunciado describe columnas separadas por comas, el archivo efectivamente procesado utiliza punto y coma como delimitador. La implementación explicita este criterio para evitar interpretaciones ambiguas.

Cuadro 2.1: Diccionario resumido de variables de entrada.

Variable	Tipo esperado	Descripción
FECHA	Fecha-hora	Fecha y hora de la transacción o emisión de la boleta, en formato ISO 8601.
CANAL	Categoría	Canal de compra: APP, CCT, POS o WEB.
SKU	Entero	Identificador del producto.
PRODUCTO	Texto	Denominación comercial del producto.
UNIDADES	Entero	Cantidad adquirida en la transacción.
PORCENTAJE DESCUENTO	Real	Proporción de descuento entre 0 y 1.
MONTO APLICADO	Real	Monto total pagado en pesos chilenos.
BOLETA	Entero	Número de boleta.
LOCAL	Entero	Identificador del local.
CODIGO CLIENTE	<i>UUID</i>	Identificador único del cliente.
RUN CLIENTE	Texto	RUN chileno con dígito verificador.
NOMBRES	Texto	Nombres del cliente.

Variable	Tipo esperado	Descripción
APELLIDOS	Texto	Apellidos del cliente.
FECHA NACIMIENTO	Fecha	Fecha de nacimiento del cliente.
GENERO	Entero	Código de género registrado.

2.2 Entorno de ejecución documentado

La evidencia disponible permite documentar los elementos presentados en la Tabla 2.2. Las especificaciones exactas del procesador y de la memoria RAM no quedaron registradas en los artefactos de ejecución; por ello, el informe no inventa esos valores y los declara como una limitación de reproducibilidad.

Cuadro 2.2: Configuración de ejecución registrada.

Sistema operativo	Microsoft Windows, con ejecución mediante PowerShell.
Versión de Python	3.13.3, dentro de un entorno virtual.
Cantidad de procesos de validación	4.
Tamaño de fragmento	100.000 registros.
Ejecutor principal	<i>ProcessPoolExecutor</i> ; también existe una alternativa mediante hilos.
Semilla	Variable de entorno <code>CPYD_SEED</code> ; valor predeterminado 42.
Procesador y RAM	No registrados en los archivos aportados.
Formato intermedio/-final	<i>Parquet</i> .

Precaución metodológica

Para que futuros resultados de rendimiento sean plenamente comparables, cada ejecución deberá registrar modelo del procesador, cantidad de núcleos físicos y lógicos, memoria RAM, versión exacta del sistema operativo, tipo de almacenamiento y carga concurrente del equipo.

2.3 Reproducibilidad

Toda operación aleatoria consulta la variable de entorno `CPYD_SEED`. Cuando dicha variable no existe, el orquestador fija el valor 42. La semilla controla el muestreo de gráficos, la selección de la muestra del modelo y la partición de entrenamiento y prueba. El siguiente comando reproduce la ejecución principal:

```
$env:CPYD_SEED="42"
python scripts\run_pipeline.py '
  --input data\ventas_completas.csv '
  --chunksize 100000 '
  --workers 4 '
  --executor process
```

Arquitectura de la solución y paralelismo

3.1 Flujo general

La solución se divide en cuatro etapas encadenadas:

1. **Validación paralela:** lectura por fragmentos y validación independiente de filas.
2. **Preprocesamiento:** conversión de tipos, variables derivadas, valores atípicos y estandarización.
3. **Análisis exploratorio:** estadísticas, pruebas y visualizaciones.
4. **Inferencia y modelado:** hipótesis, regresión lineal interpretable y modelo no lineal.

El orquestador ejecuta cada fase en orden y detiene el flujo cuando una etapa devuelve un error. El archivo validado intermedio se elimina por defecto después de generar el conjunto limpio, lo que evita mantener copias grandes innecesarias.

3.2 Validación paralela por fragmentos

La validación divide el archivo en fragmentos de 100.000 filas y envía cada bloque a un proceso independiente. Cada proceso devuelve filas válidas, registros descartados y conteos. Los procesos no escriben directamente en el archivo compartido. El proceso principal centraliza la escritura y utiliza el índice del fragmento para preservar el orden determinista.

Algoritmo 1 Validación paralela y escritura determinista

Entrada: Archivo *CSV* de entrada, tamaño de fragmento c , cantidad de procesos w **Salida:** Archivo validado en formato *Parquet* y registro de descartes

- 1: Abrir el archivo de entrada en modo secuencial
 - 2: Leer y validar el encabezado
 - 3: Crear un conjunto de procesos con capacidad w
 - 4: Inicializar *siguiente* $\leftarrow 0$ y un búfer vacío
 - 5: **para** cada fragmento i de hasta c filas **hacer**
 - 6: Enviar $(i, \text{fragmento})$ a un proceso para validar sus filas
 - 7: **mientras** la cantidad de tareas pendientes supera el límite **hacer**
 - 8: Esperar la finalización de al menos una tarea
 - 9: Guardar el resultado en el búfer usando su índice
 - 10: **mientras** el búfer contiene el fragmento *siguiente* **hacer**
 - 11: Escribir filas válidas y descartes del fragmento *siguiente*
 - 12: *siguiente* $\leftarrow \text{siguiente} + 1$
 - 13: **end mientras**
 - 14: **end mientras**
 - 15: **end para**
 - 16: Esperar las tareas restantes y vaciar el búfer en orden
 - 17: Cerrar el escritor y emitir el resumen final
-

3.3 Control de memoria y condiciones de carrera

El archivo original no se carga completamente durante la validación. El proceso principal conserva únicamente una cantidad acotada de fragmentos pendientes. La escritura centralizada evita corrupción del archivo, intercalado de líneas y condiciones de carrera. El formato *Parquet* reduce el tamaño en disco, mantiene tipos de datos y acelera las lecturas posteriores.

En el análisis exploratorio y en el modelado se paralelizan tareas independientes, no filas individuales. Los gráficos se generan de manera controlada porque Matplotlib no garantiza seguridad cuando varias tareas escriben simultáneamente sobre el mismo estado gráfico.

3.4 Rendimiento observado

Cuadro 3.1: Métricas registradas de rendimiento y volumen.

Métrica	Valor
Filas leídas	3.242.878
Fragmentos procesados	33
Tiempo de validación paralela	65,18 s
Tiempo del flujo sin abrir el <i>dashboard</i>	142,6 s
Tiempo aproximado con apertura del <i>dashboard</i>	180 s
Tamaño del conjunto limpio	275 MB aprox.

3.4.1 Comparación de estrategias disponibles

El programa permite seleccionar procesos o hilos mediante el argumento `-executor`. Sin embargo, solo quedó documentado un tiempo correspondiente a la versión con procesos. Por esta razón, no se presenta un *speedup* artificial.

Cuadro 3.2: Estado de las estrategias de ejecución.

Estrategia	Disponibilidad	Uso previsto	Tiempo registrado
Secuencial	No instrumentada como línea base	Referencia necesaria para calcular aceleración y eficiencia.	No disponible
Hilos	Implementada	Alternativa útil cuando domina la espera de entrada/salida.	No disponible
Procesos	Implementada y utilizada	Validación intensiva en CPU, evitando la limitación del intérprete para código Python.	65,18 s

El *speedup* y la eficiencia se definen como:

$$S_p = \frac{T_1}{T_p}, \quad E_p = \frac{S_p}{p},$$

donde T_1 representa el tiempo secuencial, T_p el tiempo con p procesos y p la cantidad de procesos. Sin una medición de T_1 bajo el mismo equipo y condiciones, ambas métricas

permanecen indeterminadas. Esta decisión evita atribuir al paralelismo una ganancia que no fue medida.

Datos y preprocesamiento

4.1 Validación de calidad

Cada transacción se somete a reglas de formato y dominio: cantidad correcta de columnas, campos obligatorios, valores numéricos positivos, descuento entre 0 y 1, RUN válido, *UUID* válido, fechas parseables, edad entre 0 y 110 años al momento de la compra y código de género permitido.

Cuadro 4.1: Resultados de validación del archivo original.

Resultado	Cantidad
Filas leídas	3.242.878
Filas válidas	3.239.993
Filas descartadas	2.885
Descartadas por edad fuera de rango	2.876
Descartadas por otras reglas	9

La tasa de conservación fue aproximadamente del 99,91 %. Las razones de descarte se almacenan en el archivo `logs.txt`. Para cada registro rechazado, este archivo guarda el número de línea, la variable involucrada, la causa del descarte y el valor observado, lo que permite auditar el proceso de validación.

4.2 Valores faltantes

El conjunto validado no presentó valores faltantes: se evaluaron 3.239.993 filas y el conteo total fue cero. En consecuencia, no se aplicó una imputación efectiva en esta ejecución. El código mantiene reglas deterministas de respaldo para imputar la mediana del descuento y una fecha fija de nacimiento cuando futuras entradas contengan ausencias.

No corresponde aplicar una prueba de Little MCAR cuando no existen ausencias. El reporte generado conserva la estructura necesaria para evaluar asociaciones entre indicadores de ausencia y variables observadas si el problema aparece en una ejecución posterior.

4.3 Variables derivadas

La etapa de preprocesamiento construyó tres variables:

$$\text{MONTO POR UNIDAD} = \frac{\text{MONTO APLICADO}}{\text{UNIDADES}}, \quad (4.1)$$

$$\text{EDAD} = \frac{\text{FECHA-TRANSACCION} - \text{FECHA-NACIMIENTO}}{365,25}, \quad (4.2)$$

$$\text{FRECUENCIA-COMPRA}_i = \#\{\text{transacciones del cliente } i\}. \quad (4.3)$$

La edad se calcula utilizando la fecha de cada boleta o transacción, representada por el campo **FECHA**, y no la fecha actual. De este modo, la variable **EDAD** representa la edad que tenía el cliente exactamente al momento de realizar la compra.

Debido a que **UNIDADES**=1 en todas las filas limpias, **MONTO POR UNIDAD** coincide exactamente con **MONTO APLICADO**. Ambas variables no deben incorporarse simultáneamente en un modelo lineal porque contienen información duplicada.

4.4 Valores atípicos

Los valores atípicos se identificaron mediante el rango intercuartílico. Para una variable X , se definieron los límites:

$$L_{\text{inf}} = Q_1 - 1,5 \text{ IQR}, \quad L_{\text{sup}} = Q_3 + 1,5 \text{ IQR}.$$

El procedimiento marcó 212.351 transacciones como atípicas en monto, equivalentes a cerca del 6,55 % del conjunto limpio. Los casos no se eliminaron automáticamente, porque pueden representar compras reales de alto valor y no errores de captura.

4.5 Estandarización

Las variables numéricas se expresaron también mediante puntuación estándar:

$$z = \frac{x - \bar{x}}{s}.$$

Los parámetros de media y desviación se guardaron en un archivo *JSON*. Cuando la desviación fue cero, como ocurre con UNIDADES, el programa asignó cero a la columna estandarizada para evitar una división indefinida. Esta columna no aporta información analítica y se excluye de interpretaciones sustantivas.

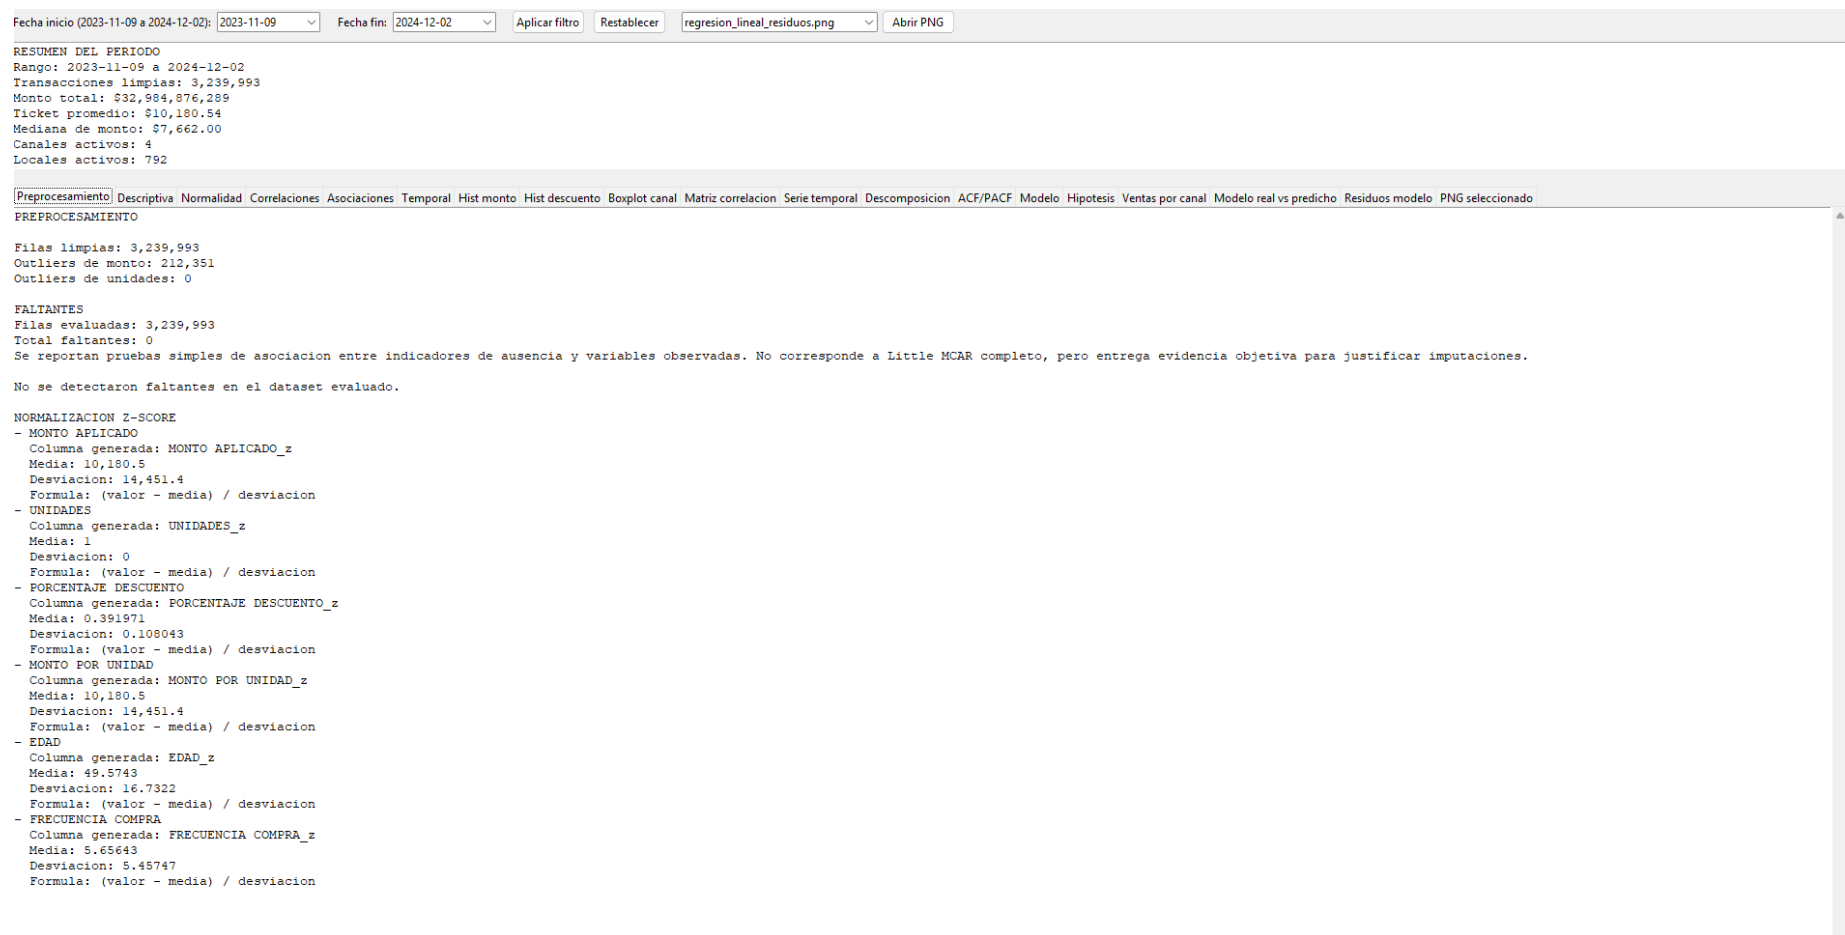


Figura 4.1: Resumen del periodo y resultados de preprocesamiento presentados por el *dashboard*.

Análisis exploratorio estadístico

5.1 Estadística descriptiva

Cuadro 5.1: Estadísticas descriptivas principales.

Variable	Media	Mediana	Desv. est.	Mínimo	Máximo	Asimetría
UNIDADES	1,00	1,00	0,00	1,00	1,00	0,00
PORCENTAJE DESCUENTO	0,3920	0,4000	0,1080	0,00	1,00	0,2966
MONTO APLICADO	10.180,54	7.662,00	14.451,43	15,00	226.476,00	9,0606
MONTO POR UNIDAD	10.180,54	7.662,00	14.451,43	15,00	226.476,00	9,0606
EDAD	49,57	48,61	16,73	0,01	109,85	0,2419
FRECUENCIA COMPRA	5,66	4,00	5,46	1,00	110,00	3,2552

La diferencia entre media y mediana del monto, sumada a una asimetría de 9,06 y una curtosis de 108,24, evidencia una cola derecha extensa. La mediana representa mejor una transacción típica que la media. La frecuencia de compra también presenta asimetría positiva: una fracción reducida de clientes concentra muchas operaciones.

ESTADISTICA DESCRIPTIVA

Incluye tendencia central, dispersion, asimetria y curtosis para variables numericas.

```
- UNIDADES
n: 3,239,993
media: 1
mediana: 1
desviacion: 0
varianza: 0
minimo: 1
maximo: 1
asimetria: 0
curtosis: 0

- PORCENTAJE DESCUENTO
n: 3,239,993
media: 0.391971
mediana: 0.4
desviacion: 0.108043
varianza: 0.0116733
minimo: 0
maximo: 1
asimetria: 0.296589
curtosis: 2.84826

- MONTO APLICADO
n: 3,239,993
media: 10,180.5
mediana: 7,662
desviacion: 14,451.4
varianza: 2.08844e+08
minimo: 15
maximo: 226,476
asimetria: 9.06061
curtosis: 108.243

- MONTO POR UNIDAD
n: 3,239,993
media: 10,180.5
mediana: 7,662
desviacion: 14,451.4
varianza: 2.08844e+08
minimo: 15
maximo: 226,476
asimetria: 9.06061
curtosis: 108.243
```

(a) Variables iniciales.

```
- EDAD
n: 3,239,993
media: 49.5743
mediana: 48.6078
desviacion: 16.7322
varianza: 279.965
minimo: 0.0054757
maximo: 109.845
asimetria: 0.241881
curtosis: -0.784239

- FRECUENCIA COMPRA
n: 3,239,993
media: 5.65643
mediana: 4
desviacion: 5.45747
varianza: 29.784
minimo: 1
maximo: 110
asimetria: 3.25515
curtosis: 21.5104
```

(b) Edad y frecuencia.

Figura 5.1: Estadística descriptiva mostrada en el *dashboard*.

5.2 Distribuciones y normalidad

Las pruebas de Shapiro–Wilk y Kolmogorov–Smirnov rechazaron la normalidad para todas las variables evaluables. UNIDADES no pudo evaluarse porque carece de variación. Con muestras grandes, estas pruebas detectan desviaciones pequeñas; por ello, la decisión se complementó con histogramas, asimetría y curtosis.

```
NORMALIDAD

- UNIDADES
  Shapiro stat: N/A
  Shapiro p-value: N/A
  KS stat: N/A
  KS p-value: N/A
- PORCENTAJE DESCUENTO
  Shapiro stat: 0.854933
  Shapiro p-value: 1.12301e-55
  KS stat: 0.194754
  KS p-value: 1.28932e-166
- MONTO APLICADO
  Shapiro stat: 0.339513
  Shapiro p-value: 2.77314e-86
  KS stat: 0.277564
  KS p-value: 0
- MONTO POR UNIDAD
  Shapiro stat: 0.339513
  Shapiro p-value: 2.77314e-86
  KS stat: 0.277564
  KS p-value: 0
- EDAD
  Shapiro stat: 0.978183
  Shapiro p-value: 4.87706e-27
  KS stat: 0.0501469
  KS p-value: 0
- FRECUENCIA COMPRA
  Shapiro stat: 0.703424
  Shapiro p-value: 2.90942e-69
  KS stat: 0.201183
  KS p-value: 7.15824e-178
```

Figura 5.2: Resultados de las pruebas de normalidad.




Figura 5.3: Distribución del monto aplicado. La cola derecha confirma la presencia de compras de alto valor.




Figura 5.4: Distribución del porcentaje de descuento. Se observan niveles comerciales discretos, especialmente alrededor de 20 %, 35 %, 40 % y 50 %.

5.3 Correlaciones

Debido a la no normalidad y a la presencia de valores atípicos, se utilizó la correlación de Spearman. Los resultados más relevantes fueron:

- descuento y monto: $\rho = 0,4827$, asociación positiva moderada;
- frecuencia y monto: $\rho = 0,2245$, asociación positiva débil;
- edad y monto: $\rho = 0,0992$, asociación positiva muy débil;
- descuento y edad: $\rho = -0,0043$, sin asociación práctica.




Figura 5.5: Matriz de correlación de Spearman para el periodo completo.

```

CORRELACIONES

Matriz Spearman con p-values asociados. Valores N/A indican variables sin variacion suficiente.

- UNIDADES
UNIDADES: rho=N/A, p=0
PORCENTAJE DESCUENTO: rho=N/A, p=N/A
MONTO APLICADO: rho=N/A, p=N/A
MONTO POR UNIDAD: rho=N/A, p=N/A
EDAD: rho=N/A, p=N/A
FRECUENCIA COMPRA: rho=N/A, p=N/A

- PORCENTAJE DESCUENTO
UNIDADES: rho=N/A, p=N/A
PORCENTAJE DESCUENTO: rho=1, p=0
MONTO APLICADO: rho=0.482738, p=0
MONTO POR UNIDAD: rho=0.482738, p=0
EDAD: rho=-0.00425371, p=0.069455
FRECUENCIA COMPRA: rho=0.296448, p=0

- MONTO APLICADO
UNIDADES: rho=N/A, p=N/A
PORCENTAJE DESCUENTO: rho=0.482738, p=0
MONTO APLICADO: rho=1, p=0
MONTO POR UNIDAD: rho=1, p=0
EDAD: rho=0.0991794, p=0
FRECUENCIA COMPRA: rho=0.224548, p=0

- MONTO POR UNIDAD
UNIDADES: rho=N/A, p=N/A
PORCENTAJE DESCUENTO: rho=0.482738, p=0
MONTO APLICADO: rho=1, p=0
MONTO POR UNIDAD: rho=1, p=0
EDAD: rho=0.0991794, p=0
FRECUENCIA COMPRA: rho=0.224548, p=0

- EDAD
UNIDADES: rho=N/A, p=N/A
PORCENTAJE DESCUENTO: rho=-0.00425371, p=0.069455
MONTO APLICADO: rho=0.0991794, p=0
MONTO POR UNIDAD: rho=0.0991794, p=0
EDAD: rho=1, p=0
FRECUENCIA COMPRA: rho=0.12732, p=0

- EDAD
UNIDADES: rho=N/A, p=N/A
PORCENTAJE DESCUENTO: rho=-0.00425371, p=0.069455
MONTO APLICADO: rho=0.0991794, p=0
MONTO POR UNIDAD: rho=0.0991794, p=0
EDAD: rho=1, p=0
FRECUENCIA COMPRA: rho=0.12732, p=0

- FRECUENCIA COMPRA
UNIDADES: rho=N/A, p=N/A
PORCENTAJE DESCUENTO: rho=0.296448, p=0
MONTO APLICADO: rho=0.224548, p=0
MONTO POR UNIDAD: rho=0.224548, p=0
EDAD: rho=0.12732, p=0
FRECUENCIA COMPRA: rho=1, p=0

```

(a) Primera parte de la matriz textual.

(b) Continuación.

Figura 5.6: Correlaciones y valores p presentados por el *dashboard*.

Hallazgo principal

La asociación entre descuento y monto no demuestra causalidad. El descuento puede correlacionarse con el precio base, el tipo de producto, la campaña promocional o el canal. Por ello, no corresponde concluir que aumentar el descuento causará por sí solo un mayor gasto.

5.4 Asociaciones y diferencias entre grupos

La prueba de chi-cuadrado entre canal y local obtuvo $\chi^2 = 3.239.993$, con 2.373 grados de libertad y $p < 0,001$. Se rechaza la independencia, aunque la magnitud del efecto debería complementarse con el estadístico de V de Cramér.

El monto difirió entre canales tanto bajo ANOVA ($F = 150,36$; $p < 0,001$) como bajo Kruskal–Wallis ($H = 5.937,90$; $p < 0,001$). La prueba no paramétrica aporta evidencia especialmente relevante porque la distribución del monto incumple normalidad y presenta valores atípicos.

ASOCIACIONES Y COMPARACIONES

Incluye las pruebas exigidas por el enunciado: Chi-cuadrado, Spearman y ANOVA/Kruskal.

- Chi-cuadrado | CANAL vs LOCAL
chi2: 3.23999e+06
grados_libertad: 2,373
p_value: 0
- Spearman | UNIDADES vs MONTO APLICADO
rho: N/A
p_value: N/A
nota: No evaluable: una o ambas variables no tienen variacion suficiente.
- Spearman | UNIDADES vs PORCENTAJE DESCUENTO
rho: N/A
p_value: N/A
nota: No evaluable: una o ambas variables no tienen variacion suficiente.
- Spearman | MONTO APLICADO vs PORCENTAJE DESCUENTO
rho: 0.482738
p_value: 0
nota: N/A
- ANOVA | MONTO APLICADO por CANAL
estadistico: 150.363
p_value: 1.92301e-97
nota: N/A
- Kruskal-Wallis | MONTO APLICADO por CANAL
estadistico: 5,937.9
p_value: 0
nota: N/A
- ANOVA | MONTO APLICADO por LOCAL
estadistico: 55.1246
p_value: 0
nota: Evaluado sobre los 200 locales con mas registros para controlar costo computacional.
- Kruskal-Wallis | MONTO APLICADO por LOCAL
estadistico: 24,316.6
p_value: 0
nota: Evaluado sobre los 200 locales con mas registros para controlar costo computacional.
- Chi-cuadrado | CANAL vs GENERO
chi2: 11,791.6
grados_libertad: 3
p_value: 0
nota: Prueba complementaria no exigida directamente por la rubrica.

Figura 5.7: Pruebas de asociación y comparación de grupos.




Figura 5.8: Distribución del monto aplicado según canal. CCT presenta visualmente la mediana más alta; una comparación por pares sería necesaria para identificar qué canales difieren entre sí.

5.5 Patrones temporales

El rango mostrado por el *dashboard* se extiende desde el 9 de noviembre de 2023 hasta el 2 de diciembre de 2024. La serie contiene 241 días observados. Se aprecia un cambio de nivel alrededor de abril de 2024, crecimiento durante los meses posteriores, oscilaciones semanales y variabilidad creciente.

```
PATRONES TEMPORALES

Dias observados: 241
Descomposicion temporal: generada
ACF/PACF: generada

Las pestanas Serie temporal, Descomposicion y ACF/PACF se recalculan con el filtro de fechas.
```

Figura 5.9: Resumen del análisis temporal generado.




Figura 5.10: Ventas diarias del periodo.




Figura 5.11: Descomposición aditiva de la serie temporal en componente observada, tendencia, estacionalidad y residuo.

Precaución metodológica

La amplitud de las oscilaciones aumenta con el nivel de ventas, lo que sugiere heterocedasticidad y posible conveniencia de una transformación logarítmica o una descomposición multiplicativa. Además, el tramo inicial debe verificarse para determinar si representa ventas reales muy bajas o fechas sin cobertura completa.

Inferencia estadística

6.1 Criterio de decisión

Se adoptó un nivel de significancia $\alpha = 0,05$. Cuando el programa devolvió un valor p igual a cero por precisión numérica, el informe lo expresa como $p < 0,001$. La interpretación distingue significancia estadística de relevancia práctica.

6.2 Hipótesis exigidas por el enunciado

6.2.1 Ticket promedio en APP y WEB

$$H_0 : \mu_{APP} \leq \mu_{WEB},$$

$$H_1 : \mu_{APP} > \mu_{WEB}.$$

La prueba t de Welch unilateral obtuvo $t = -5,365$ y $p = 0,99999996$. Mann–Whitney unilateral obtuvo $p = 0,3800$. En ambas pruebas no se rechazó H_0 . Los datos no respaldan que APP tenga un ticket promedio superior a WEB.

6.2.2 Descuento y unidades vendidas

$$H_0 : \beta_{descuento} = 0,$$

$$H_1 : \beta_{descuento} \neq 0.$$

La hipótesis no fue evaluable porque UNIDADES adopta exclusivamente el valor 1. Una regresión sobre una respuesta constante carece de varianza explicable. La limitación se documentó y se substituyó por una hipótesis relacionada con descuento y monto aplicado.

6.3 Hipótesis propias

6.3.1 Diferencias de monto entre canales

ANOVA y Kruskal–Wallis rechazaron la igualdad entre canales. La conclusión no técnica indica que el canal de compra se relaciona con diferencias en el monto pagado. La prueba global no identifica por sí sola qué pares difieren; se recomienda un análisis posterior de Tukey o Dunn.

6.3.2 Asociación entre descuento y monto

Spearman obtuvo $\rho = 0,4827$ y $p < 0,001$. Se rechazó la ausencia de asociación monotónica. La magnitud es moderada y positiva: los descuentos mayores tienden a coexistir con montos mayores, sin que ello implique causalidad.

6.3.3 Asociación entre edad y monto

Spearman obtuvo $\rho = 0,0992$ y $p < 0,001$. Aunque se rechazó H_0 , el tamaño del efecto es muy pequeño. El gran volumen de datos permite detectar relaciones de escasa relevancia práctica.

6.3.4 Diferencias de monto según género

La prueba t de Welch obtuvo $t = 45,019$ y Mann–Whitney también produjo $p < 0,001$. Se rechazó la igualdad de distribuciones. La interpretación requiere cautela porque el

resultado puede estar confundido por canal, edad, frecuencia, productos y local.

Cuadro 6.1: Resumen de decisiones inferenciales.

Hipótesis	Prueba	Resultado	Interpretación
APP > WEB	Welch y Mann–Whitney	No se rechaza H_0	No existe evidencia de superioridad de APP.
Descuento y unidades	Regresión/ANCOVA	No evaluable	La respuesta carece de variación.
Monto por canal	ANOVA y Kruskal–Wallis	Se rechaza H_0	Existen diferencias entre canales.
Descuento y monto	Spearman	$\rho = 0,4827$, $p < 0,001$	Asociación positiva moderada.
Edad y monto	Spearman	$\rho = 0,0992$, $p < 0,001$	Asociación estadística, pero débil.
Monto y género	Welch y Mann–Whitney	Se rechaza H_0	Existen diferencias que requieren control de confusores.

Modelado predictivo y descriptivo

7.1 Modelo no lineal principal

El modelo principal fue *HistGradientBoostingRegressor*. La variable objetivo se transformó mediante:

$$y^* = \log(1 + y),$$

con el propósito de reducir el efecto de la cola derecha. Se utilizó una muestra reproducible de 500.000 filas, dividida en 350.000 observaciones de entrenamiento y 150.000 de prueba.

Los predictores fueron porcentaje de descuento, edad, frecuencia de compra, SKU, género, local, mes, día de la semana, hora y variables indicadoras de canal. UNIDADES aparece en la lista técnica, pero al ser constante no entrega ganancia informativa.

Cuadro 7.1: Desempeño del modelo no lineal en el conjunto de prueba.

Métrica	Valor
MAE	\$1.683,57
RMSE	\$3.651,64
R^2	0,9368

El modelo explica aproximadamente el 93,7 % de la variabilidad del monto dentro de una partición aleatoria de datos similares a los observados. El RMSE supera al MAE porque penaliza con mayor intensidad los errores grandes.

7.2 Regresión lineal interpretable

Para satisfacer la opción de regresión del enunciado, se ajustó un modelo OLS sobre $\log(1 + \text{MONTTO APLICADO})$. La muestra incluyó 200.000 filas, con 140.000 para entrenamiento y 60.000 para prueba. UNIDADES se excluyó automáticamente por falta de variación.

Cuadro 7.2: Desempeño de la regresión lineal.

Métrica	Valor
R^2 de entrenamiento	0,2470
R^2_{ajustado} de entrenamiento	0,2470
MAE de prueba	\$4.905,58
RMSE de prueba	\$12.827,85
R^2 de prueba	0,2300

El coeficiente del descuento fue 3,3566 en escala logarítmica. Bajo los supuestos del modelo, un aumento de 0,10 en el descuento se asociaría con un cambio multiplicativo aproximado de $e^{0,33566} - 1 \approx 39,9\%$ en el monto esperado, manteniendo constantes los demás predictores. Esta interpretación debe tratarse con cautela porque el modelo presenta bajo poder explicativo, heterocedasticidad y residuos no normales.

Cuadro 7.3: Diagnósticos principales de la regresión lineal.

Diagnóstico	Resultado	Conclusión
Jarque–Bera	22.272,12; $p < 0,001$	Los residuos no siguen normalidad.
Shapiro–Wilk	0,9781; $p < 0,001$	Confirma desviación de normalidad.
Breusch–Pagan	$p < 0,001$	Se rechaza homocedasticidad.
VIF descuento	11,87	Existe una señal de multicolinealidad elevada.
VIF canal POS	11,61	La interpretación individual requiere cautela.

7.3 Comparación de modelos

Cuadro 7.4: Comparación predictiva entre modelos.

Modelo	MAE	RMSE	R^2
<i>HistGradientBoostingRegressor</i>	1.683,57	3.651,64	0,9368
OLS interpretable	4.905,58	12.827,85	0,2300

El modelo no lineal ofrece mayor precisión porque representa interacciones y relaciones no lineales entre producto, local, descuento, canal y tiempo. La regresión lineal conserva valor explicativo al mostrar coeficientes y diagnósticos, pero no constituye la mejor alternativa predictiva.

MODELO

Modelo: HistGradientBoostingRegressor
Objetivo: MONTO APLICADO
Transformacion objetivo: loglp
Muestra maxima: 500,000
Filas usadas: 500,000
Train: 350,000
Test: 150,000

METRICAS

MAE: 1,683.57
RMSE: 3,651.64
R2: 0.936755

PREDICTORES

- UNIDADES
- PORCENTAJE DESCUENTO
- EDAD
- FRECUENCIA COMPRA
- SKU
- GENERO
- LOCAL
- FECHA_MES
- FECHA_DIA_SEMANA
- FECHA_HORA
- CANAL_CCT
- CANAL_POS
- CANAL_WEB

REGRESION LINEAL INTERPRETABLE

Modelo: OLS
Objetivo: loglp(MONTO APLICADO)
Filas usadas: 200,000
Train: 140,000
Test: 60,000
R2 train: 0.247034
R2 ajustado train: 0.247007

Metricas test escala original:

- MAE: 4,905.58
- RMSE: 12,827.8
- R2: 0.230012

Figura 7.1: Resumen de los modelos y métricas presentado por el *dashboard*.

7.4 Extrapolabilidad y riesgos de validación

La extrapolabilidad es limitada fuera de los rangos observados. El modelo no garantiza precisión para nuevos locales, productos o canales. Además, la partición aleatoria puede situar transacciones del mismo producto y periodos cercanos en entrenamiento y prueba, lo que produce una evaluación más favorable que una predicción estrictamente futura.

Para evaluar capacidad prospectiva se recomienda ordenar por fecha, entrenar con periodos anteriores y reservar los meses finales como prueba. También se recomienda tratar SKU, local y género como variables categóricas explícitas, pues sus códigos no representan distancias cuantitativas naturales.

Dashboard y comunicación de resultados

El *dashboard* local permite seleccionar un intervalo de fechas, recalcular visualizaciones y consultar resultados tabulares. La interfaz organiza la evidencia en pestañas de preprocesamiento, estadística descriptiva, normalidad, correlaciones, asociaciones, temporalidad, modelo e hipótesis.

La aplicación facilita la comunicación con usuarios no especializados, pero no reemplaza el análisis metodológico. En particular, un valor p pequeño debe acompañarse de tamaño del efecto, supuestos y contexto de negocio.

Hallazgo principal

El periodo completo contiene 3.239.993 transacciones, un monto total cercano a \$32.984.876.289, un ticket promedio de \$10.180,54, una mediana de \$7.662, cuatro canales y 792 locales activos.

Dificultades, soluciones y lecciones aprendidas

Cuadro 9.1: Dificultades estructuradas por problema, causa, solución y lección.

Problema	Causa	Solución aplicada	Lección aprendida
Consumo de memoria	El archivo contiene más de 3,2 millones de filas.	Lectura por fragmentos y uso de <i>Parquet</i> para resultados intermedios.	La arquitectura de datos debe definirse antes de aplicar estadísticas.
Escritura concurrente insegura	Varios procesos podrían escribir simultáneamente.	Escritura exclusiva desde el proceso principal y búfer ordenado por índice.	El paralelismo debe aislar tareas y centralizar recursos compartidos.
Resultados fuera de orden	Los fragmentos terminan en tiempos distintos.	El proceso principal escribe únicamente el siguiente índice esperado.	Determinismo y paralelismo son compatibles cuando se controla el orden de salida.
Variable sin variación	Todas las filas limpias contienen una unidad.	Las pruebas se marcaron como no evaluables y el modelo lineal excluyó la variable.	Antes de elegir una prueba se debe verificar la varianza de cada variable.
Distribución no normal	Los montos presentan cola derecha y valores extremos.	Uso de Spearman, Kruskal–Wallis, Mann–Whitney y transformación $\log(1 + y)$.	Los supuestos deben guiar la selección de la técnica, no solo la rúbrica.

Problema	Causa	Solución aplicada	Lección aprendida
Conflictos gráficos	Matplotlib mantiene estado compartido.	Generación controlada de gráficos y uso de bloqueo en tareas concurrentes.	No todas las etapas se benefician del paralelismo de la misma forma.
Falta de línea base secuencial	No se registró una ejecución equivalente con un proceso.	Se informó el tiempo paralelo sin inventar <i>speedup</i> .	Toda evaluación de rendimiento debe instrumentarse antes de comparar versiones.
Hardware incompleto	CPU y RAM no quedaron registrados.	Se declaró la limitación y se propuso incorporarlos en futuras ejecuciones.	La reproducibilidad incluye software, datos y características del equipo.

Limitaciones metodológicas

1. UNIDADES es constante, por lo que impide contrastar una de las hipótesis originales y no aporta información predictiva.
2. Los valores p extremadamente pequeños se explican parcialmente por el gran tamaño muestral; siempre deben acompañarse de tamaños de efecto.
3. Los valores atípicos se marcan, pero no se clasifican individualmente como errores o eventos reales de negocio.
4. La prueba chi-cuadrado no incluye una medida de tamaño de efecto como V de Cramér.
5. ANOVA se aplicó pese a la no normalidad; Kruskal–Wallis se utilizó como contraste robusto complementario.
6. No se ejecutaron comparaciones *post hoc* para determinar qué pares de canales o locales difieren.
7. La descomposición temporal aditiva puede ser insuficiente frente a una variabilidad creciente.
8. La validación aleatoria del modelo no simula de forma estricta la predicción de periodos futuros.
9. SKU, local y género se representan mediante códigos numéricos en el modelo principal; esta codificación puede introducir un orden artificial.
10. No se registraron procesador, memoria RAM ni línea base secuencial, por lo que no es posible calcular *speedup* y eficiencia.

Cumplimiento de la rúbrica

Cuadro 11.1: Matriz de cumplimiento del enunciado.

Requisito	Estado	Evidencia
Carga del archivo desde línea de comandos	Cumplido	Argumento <code>-input</code> .
Procesamiento por fragmentos	Cumplido	Fragmentos de 100.000 filas.
Procesamiento paralelo	Cumplido	Cuatro procesos en validación; tareas independientes en EDA/modelado.
Semilla mediante <code>CPYD_SEED</code>	Cumplido	Valor predeterminado 42.
Tratamiento de faltantes	Cumplido	Reporte completo; no se detectaron ausencias.
Detección de valores atípicos	Cumplido	Criterio IQR y 212.351 casos marcados.
Variables derivadas	Cumplido	Monto por unidad, edad y frecuencia.
Estadísticas descriptivas	Cumplido	Tendencia central, dispersión, asimetría y curtosis.
Histogramas y normalidad	Cumplido	Shapiro–Wilk, Kolmogorov–Smirnov e histogramas.
Boxplots por categoría	Cumplido	Monto por canal.
Correlación con significancia	Cumplido	Spearman y valores p .
Chi-cuadrado	Cumplido	Canal–local y canal–género.
ANOVA y prueba robusta	Cumplido	ANOVA y Kruskal–Wallis.

Requisito	Estado	Evidencia
Patrones temporales	Cumplido	Serie diaria, descomposición y ACF/PACF generadas.
Dos hipótesis propuestas por el enunciado	Cumplido con limita- ción	Una no evaluable por res- puesta constante.
Tres hipótesis propias	Cumplido	Canal, descuento, edad y gé- nero.
Modelo predictivo/descriptivo	Cumplido	Gradiente reforzado y OLS.
División 70/30 y métricas	Cumplido	MAE, RMSE y R^2 .
Discusión de extrapolabilidad	Cumplido	Limitaciones y propuesta de validación temporal.

Conclusiones y recomendaciones

La solución procesó de forma reproducible más de 3,2 millones de transacciones y mantuvo el consumo de memoria bajo control mediante lectura por fragmentos. La validación paralela centralizó la escritura y conservó el orden de los registros, lo que evitó condiciones de carrera y aseguró determinismo.

El análisis estadístico mostró que el monto aplicado posee una distribución altamente asimétrica y que la mediana representa mejor una compra típica. Se detectaron diferencias significativas entre canales y una relación positiva moderada entre descuento y monto. La edad presentó una asociación estadísticamente significativa pero de baja magnitud, lo que ejemplifica la diferencia entre significancia y relevancia práctica.

El modelo *HistGradientBoostingRegressor* alcanzó un rendimiento alto dentro de la partición aleatoria utilizada. No obstante, el desempeño no debe interpretarse como causal ni como garantía de predicción futura. La regresión lineal complementaria fue menos precisa y presentó incumplimiento de normalidad y homocedasticidad, aunque permitió inspeccionar coeficientes y multicolinealidad.

Para una siguiente versión se recomienda: registrar hardware y tiempos con uno, dos, cuatro y ocho procesos; calcular *speedup* y eficiencia; aplicar validación temporal; codificar apropiadamente variables categóricas; incorporar V de Cramér; ejecutar pruebas *post hoc*; comparar descomposición aditiva y multiplicativa; y añadir variables externas como feriados, campañas, disponibilidad de stock y categoría de producto.

Comandos de ejecución

```
# Activar el entorno virtual en PowerShell
.\.venv\Scripts\Activate.ps1

# Instalar dependencias
pip install -r requirements.txt

# Ejecutar el flujo completo
$env:CPYD_SEED="42"
python scripts\run_pipeline.py '
    --input data\ventas_completas.csv '
    --chunksize 100000 '
    --workers 4 '
    --executor process

# Ejecutar sin abrir el dashboard
python scripts\run_pipeline.py '
    --input data\ventas_completas.csv '
    --chunksize 100000 '
    --workers 4 '
    --executor process '
    --no-dashboard
```

Glosario

<i>ACF</i>	Función de autocorrelación; cuantifica la relación de una serie con sus propios rezagos.
ANOVA	Análisis de varianza para comparar medias entre varios grupos.
<i>Boxplot</i>	Diagrama de caja que resume mediana, cuartiles y posibles valores atípicos.
<i>Chunk</i>	Fragmento de filas procesado como una unidad acotada de trabajo.
<i>CSV</i>	Formato de texto tabular con valores separados por un delimitador.
<i>Dashboard</i>	Interfaz que reúne indicadores, filtros y visualizaciones.
EDA	Análisis exploratorio de datos.
<i>JSON</i>	Formato textual para almacenar estructuras de datos y resultados.
MAE	Error absoluto medio entre valores reales y predichos.
MCAR	Mecanismo en que la ausencia de datos es completamente aleatoria.
OLS	Mínimos cuadrados ordinarios para estimar una regresión lineal.
<i>Outlier</i>	Observación que se aleja notablemente del comportamiento central.
<i>PACF</i>	Función de autocorrelación parcial.
<i>Parquet</i>	Formato columnar binario eficiente para análisis de datos.
<i>Pipeline</i>	Secuencia automatizada de etapas dependientes.

RMSE	Raíz del error cuadrático medio; penaliza con mayor intensidad los errores grandes.
<i>Seed</i>	Semilla que fija la secuencia pseudoaleatoria y permite reproducir resultados.
<i>Speedup</i>	Razón entre el tiempo secuencial y el tiempo paralelo.
<i>Train/test</i>	División entre datos utilizados para ajustar y evaluar un modelo.
VIF	Factor de inflación de la varianza para diagnosticar multicolinealidad.
<i>UUID</i>	Identificador universal único.
<i>Worker</i>	Proceso o hilo que ejecuta una tarea asignada.

Justificación de bibliotecas

- *pandas*: lectura, transformación tabular y manejo de fechas.
- *NumPy*: operaciones vectorizadas y estructuras numéricas.
- *SciPy*: pruebas de hipótesis y distribuciones estadísticas.
- *statsmodels*: regresión OLS, VIF, Breusch–Pagan y análisis temporal.
- *scikit-learn*: partición de datos, métricas y modelo de gradiente reforzado.
- Matplotlib y *seaborn*: generación de gráficos estadísticos.
- *PyArrow*: lectura y escritura eficiente en formato *Parquet*.
- *concurrent.futures*: administración de procesos e hilos mediante una interfaz de alto nivel.

Bibliografía

- [1] W. McKinney, «Data Structures for Statistical Computing in Python», *Proceedings of the 9th Python in Science Conference*, 2010.
- [2] C. R. Harris et al., «Array programming with NumPy», *Nature*, vol. 585, 2020.
- [3] P. Virtanen et al., «SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python», *Nature Methods*, vol. 17, 2020.
- [4] F. Pedregosa et al., «Scikit-learn: Machine Learning in Python», *Journal of Machine Learning Research*, vol. 12, 2011.
- [5] S. Seabold y J. Perktold, «Statsmodels: Econometric and Statistical Modeling with Python», *Proceedings of the 9th Python in Science Conference*, 2010.
- [6] J. D. Hunter, «Matplotlib: A 2D Graphics Environment», *Computing in Science & Engineering*, vol. 9, núm. 3, 2007.
- [7] R. J. Hyndman y G. Athanasopoulos, *Forecasting: Principles and Practice*, 3.^a ed., OTexts, 2021.